



Universidad de Buenos Aires
Facultad de Ciencias Exactas y Naturales
Departamento de Ciencias de la Computación

***Towards Evaluating Adaptivity of Model-Based
Reinforcement Learning Methods***

Aprendizaje Reforzado - Monografía

Alejandro Uribe

10 de febrero de 2025

Índice

1. Introducción	3
1.1. Aprendizaje por Refuerzo	3
1.2. El problema de la adaptabilidad	4
1.3. LoCA: Adaptación de Cambio Local	5
2. Desarrollo	7
2.1. Versión mejorada de <i>LoCA</i>	7
2.2. PlaNet y DreamerV2	8
2.3. ReacherLoCA	9
2.4. Buffer de repetición	10
2.5. Curvas de aprendizaje	10
3. Conclusiones	12
3.1. Implicaciones de los hallazgos	13
3.2. Trabajo futuro	14

Índice de figuras

1. Relaciones entre experiencia, modelo, función de valor y política en un contexto de aprendizaje por refuerzo con modelo (MBRL) y sin modelo (MFRL).	4
2. Diagrama de las fases de <i>LoCA</i>	6
3. Diagrama del dominio <i>ReacherLoCA</i>	9
4. Curvas de aprendizaje de los modelos <i>PlaNet</i> y <i>DreamerV2</i>	11
5. Mapas de calor de la recompensa predicha por <i>DreamerV2</i> en las Fases de <i>ReacherLoCA</i>	12

Índice de tablas

1. Recompensas para las tareas <i>A</i> y <i>B</i> para las zonas T_1 y T_2	6
---	---

1. Introducción

1.1. Aprendizaje por Refuerzo

El aprendizaje por refuerzo, *RL* por sus siglas en inglés, es un área del *aprendizaje automático* que estudia cómo un agente aprende a tomar decisiones óptimas interaccionando con un entorno para alcanzar un objetivo a largo plazo. A diferencia de otros enfoques de aprendizaje automático, el paradigma en cuestión no requiere de un conjunto de datos o modelos del entorno. En cambio, el agente aprende a través de la experiencia, recibiendo penalizaciones o recompensas por la acción tomada.

Entre los subelementos de un sistema de aprendizaje por refuerzo se encuentran: *política*, *recompensa*, *función de valor* y (opcionalmente) un *modelo del entorno*. La *política* es una función que mapea un estado a una acción, es decir, determina la acción a tomar en un estado dado. La *recompensa* es una señal que indica al agente si la acción tomada fue correcta o no. La *función de valor* es una función que estima la recompensa esperada de un estado o acción, es decir, determina la recompensa que el agente puede acumular en el futuro, dado un estado. Por último, el *modelo* es una representación del entorno que el agente puede usar para simular el comportamiento del entorno dado un estado y acción [1]. Los modelos de aprendizaje reforzado pueden clasificarse en dos categorías principales:

Aprendizaje por Refuerzo Basado en Modelo *MBRL* por sus siglas en inglés, los cuales usan las interacciones con el entorno para aprender un modelo del entorno y, posteriormente, lo usa para planificar una política. La representación interna del entorno le permite predecir el comportamiento del mismo y tomar decisiones óptimas. En general, este enfoque es más eficiente, ya que aprender una política directamente no es necesariamente más eficiente que aprender un modelo y planificar una política [1, 2, 3, 4]. Por otro lado, el aprendizaje basado en modelos se ha popularizado por su menor complejidad de muestreo. Además, han incorporado técnicas de ensambles y modelos probabilísticos para aliviar el problema de *sesgo-varianza* y alcanzar el rendimiento del aprendizaje por refuerzo sin modelo [2].

Aprendizaje por Refuerzo sin Modelo *MFRL* por sus siglas en inglés, aprenden una función de valor o política directamente de la interacción con el entorno. La función asigna un valor para cada par *estado-acción*, sin necesidad de modelar el entorno en sí mismo, la función en cuestión se utiliza para seleccionar la acción que maximice la recompensa en el largo plazo [1, 2]. Por otro lado, el método en cuestión es el enfoque más popular en la actualidad, incluso se usa como bloque de construcción en aprendizaje por refuerzo basado en modelos [1]. No obstante, su aplicación se encuentra reducida a entornos simulados, dada su alta complejidad de muestreo.

La figura 1 ilustra las relaciones entre la experiencia, el modelo, la función de valor y la política en un contexto de aprendizaje por refuerzo con y sin modelo.




Figura 1: Relaciones entre experiencia, modelo, función de valor y política en un contexto de aprendizaje por refuerzo con modelo (MBRL) y sin modelo (MFRL).

1.2. El problema de la adaptabilidad

A pesar de los avances en el aprendizaje por refuerzo y las expectativas generadas en la comunidad, aún no se cuenta con métodos estandarizados para comparar un modelo de aprendizaje por refuerzo con otro, tampoco se encuentran lineamientos que fijen una ruta para la evaluación de nuevos modelos con respecto a los ya existentes. Contar con una técnica de evaluación y comparación sistemática de modelos de aprendizaje por refuerzo, facilitaría el reconocimiento de ventajas y desventajas de un modelo y la elección de un modelo en función de las necesidades del problema a resolver y guiar a investigadores en la dirección de futuras investigaciones. Además, se busca evaluar la adaptabilidad de los modelos para resolver tareas nuevas, que compartan características con las tareas para las que fueron entrenados inicialmente y, en consecuencia, evaluar la capacidad de generalización de los modelos [2, 3].

En contraste, áreas como la visión por computadora cuentan con conjuntos de datos de código abierto y métricas estándar para evaluar el rendimiento de los modelos. Por ejemplo, el conjunto de datos *ImageNet* y la métrica *Top-1 Accuracy* [5]. Ahora bien, el aprendizaje por refuerzo sin modelo cuenta con librerías como *rllab* [6], *OpenAI Gym* [7] y *Deepmind Control Suite* [8], que permiten acceder a entornos y métodos de evaluación de modelos. No obstante, no se encuentran soluciones similares para el caso de los modelos de aprendizaje por refuerzo basados en modelos [2] dada la falta de librerías de código abierto que se asemejen al entorno de evaluación de modelos de aprendizaje por refuerzo sin modelo.

Actualmente, la comparación de modelos recae principalmente en la eficiencia de muestreo (*sample-efficiency*) en una tarea específica, la cual se refiere a la capacidad de aprendizaje de un algoritmo en función de la cantidad de datos, o en el caso del aprendizaje por refuerzo, la cantidad de interacciones con el entorno [2]. La eficiencia de muestreo de única tarea es la métrica de facto para evaluar el aprendizaje reforzado basado en modelos. No obstante, no es lo suficientemente robusta para evaluar el progreso en la investigación de aprendizaje por refuerzo basado en modelos. Primero, no distingue las mejoras que la exploración y generalización aportan por separado. Segundo, no proporciona una comparación clara con el caso ideal de un método basado en modelo. Finalmente, el hecho de evaluarse en una sola tarea no mide la relevancia que el modelo puede tener al desempeñar tareas nuevas y/o

en más de una tarea [9].

1.3. LoCA: Adaptación de Cambio Local

En la búsqueda de una solución a los problemas planteados, se desarrolló LoCA (*Local Change Adaptation regret*), el cual provee una solución para medir qué tan rápido el modelo adapta su política ante cambios en el entorno, como lo es un cambio en la tarea a resolver. El algoritmo en cuestión permite exponer modelos de aprendizaje reforzado, independiente de su funcionamiento interno, a cambios en la tarea a resolver y, en el caso de los métodos basados en modelos, estimar cuantitativamente cuán cerca se encuentra el modelo de un modelo ideal [9]. El algoritmo consta de tres fases:

Fase 1: Pre-entrenamiento en la tarea A

- **Objetivo:** Aprendizaje de una política estable, una función de valor y/o un modelo del entorno de acuerdo con la estructura de las recompensas.
- **Distribución de estados iniciales:** El agente se inicializa con estados iniciales aleatorios en el dominio del espacio de estados, lo que garantiza que el agente explora y aprende las dinámicas propias de la tarea A .
- **Recompensas:** Se usa la función de recompensas r_A , diseñada para que la política óptima transicione al estado terminal T_1 . Cuenta con un factor de descuento $0 < \gamma < 1$.

Fase 2: Pre-entrenamiento local en la tarea B

- **Objetivo:** adaptar el agente y su conocimiento a una estructura de recompensas diferente, únicamente bajo experiencias locales. Al restringir la experiencia del agente a la zona T_1 el agente adapta su política teniendo en cuenta las experiencias locales.
- **Distribución de estados iniciales:** El entrenamiento comienza con la asignación de un estado inicial aleatorio en la zona T_1 , se forza el agente a que no pueda escapar de la zona hasta terminar el episodio.
- **Recompensas:** Se usa la función de recompensas r_B cuya recompensa por transicionar al estado T_1 se encuentra reducida, se busca que el agente encuentre el estado terminal T_2 . Cuenta con un factor de descuento $0 < \gamma < 1$.

Fase 3: Entrenamiento y evaluación en la tarea B

- **Objetivo:** Evaluar qué tan bien el agente adaptó su política a la nueva tarea B después del pre-entrenamiento local en la *Fase 2*, que a diferencia de dicha fase, se le permite explorar todo el espacio de estados mientras se entrena.

- **Distribución de estados iniciales:** Se permite al agente explorar todo el espacio de estados.
- **Recompensas:** Se mide la habilidad del agente para encontrar el estado terminal T_2 con un número finito de pasos desde un estado inicial definido.

En resumen, el arreglo *LoCA* involucra la configuración de la tarea y del experimento. La configuración de la tarea usa dos funciones de recompensa, r_A y r_B en el mismo entorno, ambas tareas tienen un factor de descuento $0 < \gamma < 1$. La configuración del experimento involucra la ejecución de las tres fases, mencionadas anteriormente, con distintos objetivos de entrenamiento y distintas distribuciones de estado inicial.

La figura 2 ilustra el proceso de adaptación de un modelo de aprendizaje por refuerzo basado en modelo a través de las fases de *LoCA*.




Figura 2: Diagrama de las fases de *LoCA*.

Donde,

- ★ es el estado terminal.
- es la frontera de la zona T_1 .

Las recompensas para las tareas T_1 y T_2 se muestran en la tabla 1.

	T_1	T_2
r_A	r_{A1}	r_{A2}
r_B	r_{B1}	r_{B2}

Tabla 1: Recompensas para las tareas A y B para las zonas T_1 y T_2 .

2. Desarrollo

Los autores *Wan et al.* se vieron motivados a medir la adaptabilidad de los modelos de aprendizaje por refuerzo basado en modelos dado el momentum y la atención que ha recibido en la comunidad científica. Para ello, investigaron la adaptabilidad de los modelos PlaNet y DreamerV2 [10] con una versión mejorada del algoritmo que es más robusta, simple y que aborda las limitaciones de la versión original *LoCA* [3].

2.1. Versión mejorada de *LoCA*

Como se mencionó en la Sección 1.3, *LoCA* es un algoritmo de evaluación de adaptabilidad de modelos de aprendizaje por refuerzo basado en modelos que consta de dos configuraciones: *tarea* y *experimento*.

Los autores *Wan et al.* no modificaron la configuración de *tarea* de *LoCA*, pero sí la de *experimento*. Los cambios claves se listan a continuación:

Evaluación del desempeño El rendimiento es evaluado al medir el retorno promedio sobre los episodios de evaluación y se comparan con el retorno promedio que corresponde a la política óptima.

Distribución del estado inicial El estado inicial incluye todo el espacio de estados, y no solo un subconjunto de estados entre T_1 y T_2 como se planteó en la versión original de *LoCA*.

Evaluación en todas las fases El rendimiento es evaluada en las tres fases y no únicamente en la última fase, es decir, en el entrenamiento de la tarea A , en el entrenamiento de la tarea B en el área T_1 y en el entrenamiento de la tarea B en todo el espacio de estados.

Evaluación binaria Los resultados alimentarán un modelo de clasificación binaria para los métodos basados en modelos, capaz de determinar si un modelo se adapta a los cambios locales en el entorno o no. En cambio, el algoritmo original busca cuantificar qué tan alejado está el modelo de un proceso de adaptación ideal a la nueva tarea.

Los autores *Wan et al.* consideraron que estos cambios permitirían una evaluación más precisa de la adaptabilidad de los modelos de aprendizaje por refuerzo basado en modelos y menciona que usar el retorno esperado para evaluar la calidad de la política trae consigo varias ventajas [3]:

- Permite el uso completo del espacio de estados como distribución inicial.
- Remueve la necesidad de un hiperparámetro que defina el tiempo límite.

- Hace que el proceso evaluativo sea más flexible y robusto.
- El método de clasificación binaria simplifica la evaluación de la adaptabilidad.
- El algoritmo *LoCA* mejorado puede aplicarse a ambientes estocásticos sin modificación.

2.2. PlaNet y DreamerV2

Los modelos *PlaNet* y *DreamerV2* fueron seleccionados por los autores *Wan et al.* para evaluar su adaptabilidad con la versión mejorada de *LoCA* dadas sus características:

Rendimiento - Estado del arte Tanto *PlaNet* como *DreamerV2* son algoritmos de aprendizaje por refuerzo basado en modelos que muestran capaces de ejecutar tareas complejas, como el control continuo, con un rendimiento comparable al estado del arte.

Métodos basados en modelos con redes neuronales Ambos modelos fueron diseñados para aprender de las transiciones y contener un buffer de repetición para almacenar transiciones ya visitadas (experiencia pasada).

Planeación Espacio latente *PlaNet* aprende un modelo de dinámicas latentes desde la observación de imágenes y elige acciones tras planear en el espacio latente. El espacio latente le permite realizar predicciones a largo plazo mediante trayectorias estocásticas y determinísticas. Por otro lado, *DreamerV2* aprende comportamiento mediante imaginación latente.

Espacios de acción continuos Ambos algoritmos están diseñados para desempeñar tareas de control continuo, por lo que son útiles en problemas de control con robótica, por ejemplo el dominio de *ReacherLoCA*.

Disponibilidad e Implementación Se encuentran implementaciones disponibles para ambos métodos, lo que facilita su uso y experimentación en el dominio *ReacherLoCA*. En ambos casos requirieron cambios menores para adaptarse al entorno de evaluación.

Repetición de experiencias Ambos métodos usan un buffer de repetición, lo que los hace relevantes para medir su adaptabilidad en nuevos entornos y funciones de recompensa.

Los autores *Wan et al.* enfocaron su estudio en entender qué tan rápido el agente puede adaptarse, y si los datos sin actualizar almacenados en el buffer de repetición

interfieren con la adaptación a nuevas tareas. En caso de encontrar interferencia, si el agente puede reinicializar el buffer de repetición al inicio de la Fase 2 que, en términos del algoritmo, representa un cambio total en la tarea.

2.3. ReacherLoCA

El dominio original *Reacher* consiste en el control de la velocidad angular de un brazo robótico de dos articulaciones, con el objetivo de mover la punta de la segunda barra hacia un objetivo que se genera de manera aleatoria. Un diagrama más ilustrativo puede encontrarse en la documentación de Gymnasium¹. El agente recibe una recompensa de $r = 1$, en cada paso de tiempo t , si la punta de la barra está sobre el objetivo, el episodio termina después de 1000 pasos de tiempo y las posiciones iniciales y objetivos son generados de manera aleatoria al inicio de cada episodio. La versión *ReacherLoCA* tiene muchas de las características del dominio original, se diferencia en las siguientes características:

- **Dos objetivos:** Se agregó un segundo objetivo, y los lugares de ambos objetivos son fijos en esquinas opuestas del dominio.
- **Pasaje unidireccional:** Se agregó un pasaje unidireccional alrededor de uno de los objetivos.

Las demás características como la terminación de episodio se mantuvo intacta, terminan después de exactamente 5000 pasos de tiempo, y las recompensas r_A y r_B se aplican al dominio modificado [3].

Si bien se realizaron modificaciones al dominio original *Reacher*, se permitieron conservar la mayoría de los hiperparámetros y realizando cambios menores sobre los modelos *PlaNet* y *DreamerV2*, como se mencionó en la Sección 2.2.

La Figura 3 muestra un diagrama del dominio *ReacherLoCA*.




Figura 3: Diagrama del dominio *ReacherLoCA*.

Donde,

Las esferas rojas representan los objetivos,

Las barras amarillas representan el brazo robótico.

Las líneas punteadas la frontera de la zona T_1 .

¹<https://gymnasium.farama.org/environments/mujoco/reacher/>

2.4. Buffer de repetición

Los métodos *PlaNet* y *DreamerV2* utilizan un buffer de repetición, también llamado *conjunto de datos de experiencia*, que contiene todas las transiciones visitadas recientemente por el agente. El buffer de repetición es un mecanismo clave en el proceso de aprendizaje, ya que permite al agente aprender de experiencias pasadas y mejorar la eficiencia de la actualización de los modelos. Sin embargo, el buffer de repetición también puede ser una fuente de interferencia en la adaptación a nuevas tareas, ya que las transiciones pasadas pueden no ser relevantes para la tarea actual y su actualización no se lleva a cabo de manera expedita al cambiar de tarea, durante la Fase 2.

Los autores *Wan et al.* investigaron si el buffer de repetición afecta la adaptabilidad de los modelos en cuestión, por ello se plantearon las siguientes variantes para el algoritmo:


- **Reinicialización del buffer de repetición:** El buffer de repetición se reinicializa al inicio de la Fase 2, es decir, se vacía y se introducen cierto número de transiciones generadas siguiendo una política aleatoria.
- **Buffer de repetición sin reinicialización:** El buffer de repetición se mantiene intacto durante la Fase 2, es decir, no se vacía y se mantiene la información de las transiciones pasadas.

La primera variante busca remover conocimiento desactualizado del buffer y que se tome en cuenta únicamente la información relevante para la nueva tarea, mientras que la segunda variante busca evaluar si la información pasada puede interferir con la adaptación a la nueva tarea. No obstante, los autores encontraron un dilema con el buffer de repetición.


- Un buffer de repetición grande causa interferencia trayendo consigo información desactualizada.
- Un buffer de repetición pequeño causa que el modelo realice predicciones equivocadas para áreas no visitadas recientemente debido a un *olvido catastrófico*.

2.5. Curvas de aprendizaje

Las curvas de aprendizaje se muestran en la Figura 4 y muestran el retorno sin descuento obtenido por los agentes durante el entrenamiento en las tres fases. Las curvas muestran la evolución del rendimiento del agente en su interacción con el dominio y cómo aprende a adaptar su política a las nuevas tareas.



(a) Curvas de aprendizaje de *PlaNet*.



(b) Curvas de aprendizaje de *DreamerV2*.

Figura 4: Curvas de aprendizaje² de los modelos *PlaNet* y *DreamerV2* [3].

Las Figura 4a y 4b muestran que ninguno de los modelos lograron adaptar su política en la Fase 2, sin importar si el buffer de repetición fue reinicializado o no. Por otro lado, se apreció un bajo rendimiento en la Fase 3 en los casos en los que el buffer no fue reinicializado. Aquellos casos en los que el buffer fue reinicializado, se observó un que la recompensa predicha T_1 sobrestima la recompensa real, lo que sugiere que el modelo continúa usando información desactualizada para realizar predicciones y su proceso de planeación se ve afectado, en consecuencia el aprendizaje se ralentizó. La Figura 4a muestra que el agente estimó incorrectamente la recompensa independiente de si el buffer fue reinicializado o no.

²Para el escenario en el que el buffer de repetición se limpia al inicio de cada fase, lo reinicializamos con 50 episodios aleatorios (50000 pasos).

La Figura 5 muestra los mapas de calor de la recompensa predicha por *DreamerV2* en las Fases de *ReacherLoCA*.




Figura 5: Mapas de calor de la recompensa predicha por *DreamerV2* en las Fases de *ReacherLoCA*.

De la Figura 5d se aprecia que la recompensa predicha en la Fase 2 cuenta con una alta varianza en la estimación de la recompensa, lo que sugiere que el modelo no logra aprender la estructura de recompensa de la tarea T_2 . Por otro lado, la Figura 5e se asemeja a aquellas en las fases 1, 2 y 3 que se muestran en las Figuras 5a, 5b y 5c, respectivamente.

3. Conclusiones

La evaluación de *PlaNet* y *DreamerV2* en el dominio *ReacherLoCA* revela desafíos clave en la adaptabilidad de los métodos modernos de aprendizaje por refuerzo basado en modelos profundos (*MBRL*):

- **Adaptabilidad:** Ambos algoritmos tuvieron dificultades para ajustar sus políticas en la Fase 2 del experimento, independientemente de si se reinició el buffer de repetición. Esto sugiere una limitación fundamental en su capacidad para adaptarse rápidamente a cambios en la dinámica del entorno o la estructura de recompensas.
- **Buffer de repetición:**
 - Si el buffer no se reinició, el rendimiento en la Fase 3 fue deficiente debido a la interferencia de datos obsoletos de la Fase 1.

- La predicción de recompensas sin reinicializar el buffer mostró una sobreestimación del valor de T_1 en las Fases 2 y 3, afectando negativamente el aprendizaje del modelo y la planificación.
- **Hiperparámetros:** El rendimiento de ambos algoritmos depende de parámetros como la escala de pérdida KL , la entropía del actor y el factor de descuento, lo que resalta la necesidad de una calibración cuidadosa para nuevas tareas.
- **Predicción de recompensas:** *PlaNet* falló en la estimación del modelo de recompensa en la Fase 2, olvidando progresivamente la estructura de recompensa de T_1 a medida que avanzaba el entrenamiento.
- **Causas de falla:**
 - Olvido catastrófico de dinámicas o recompensas aprendidas previamente.
 - Interferencia de datos obsoletos en el buffer de repetición.
 - Incapacidad para explorar eficazmente el espacio de estados y detectar cambios en la estructura de recompensas.
 - Dificultades en el aprendizaje del modelo debido al uso de datos desactualizados.

3.1. Implicaciones de los hallazgos

Los desafíos de *PlaNet* y *DreamerV2* en el dominio *ReacherLoCA* tienen importantes implicaciones para el aprendizaje por refuerzo basado en modelos profundos (*MBRL*):

- **Variedad de métricas de adaptabilidad:** El *sample-efficiency* en una sola tarea no debe ser el único criterio de evaluación. Métricas como *LoCA regret* y el montaje *LoCA* ofrecen una mejor medida del comportamiento basado en modelos, comparado con el *sample-efficiency* en una sola tarea.
- **Reevaluación de las fortalezas del *MBRL*:** Se asume que *MBRL* facilita la adaptabilidad, pero los resultados muestran lo contrario. Esto desafía la creencia de que los modelos basados en aprendizaje profundo mejoran automáticamente la capacidad de adaptación y resalta la necesidad de nuevas investigaciones.
- **Olvido catastrófico:** Los algoritmos *MBRL* deben retener conocimientos previos mientras aprenden nueva información. Métodos de aprendizaje continuo, como regularización o estrategias de repetición de memoria, pueden mejorar la adaptabilidad.
- **Repensar la gestión del buffer de repetición:** Un buffer grande causa interferencia con tareas antiguas, mientras que uno pequeño provoca olvido catastrófico. Estrategias como repetición priorizada o ajuste dinámico del tamaño del buffer pueden mejorar el rendimiento.

- **Exploración basada en modelos:** Para mejorar la exploración, se pueden usar los modelos pre-entrenados para identificar regiones prometedoras del espacio de estados o integrar señales para incentivar la exploración de estados.
- **Elementos on-policy:** Aunque estos elementos mejoran la eficiencia en una sola tarea, afectan la capacidad del modelo para adaptarse rápidamente a cambios locales.
- **Aplicaciones del mundo real:** La dificultad para lograr una adaptación rápida y robusta limita la implementación de *MBRL* en áreas como robótica, conducción autónoma y gestión de recursos, donde la adaptabilidad es crucial.
- **Enfoques híbridos:** Algoritmos como *MuZero* combinan los beneficios de la planeación de alto rendimiento con métodos de refuerzo sin modelo, lo que puede ayudar a superar las limitaciones actuales.

3.2. Trabajo futuro

De la evaluación de *PlaNet* y *DreamerV2* en *ReacherLoCA* se abren posibles líneas de investigación en aprendizaje por refuerzo basado en modelos (*MBRL*):

- **Olvido catastrófico:**
 - Resolver el olvido catastrófico es crucial tanto para el entorno *LoCA* como para el aprendizaje continuo en general. Aunque se han logrado avances, aún no existe una solución completamente efectiva.
 - Se deben explorar métodos que permitan a los agentes *MBRL* retener conocimientos previos mientras se adaptan a nuevos entornos.
- **Estrategias de exploración:**
 - Desarrollar técnicas de exploración más eficientes para detectar cambios en la dinámica del entorno y la estructura de recompensas.
 - Integrar motivación intrínseca para incentivar la exploración y facilitar la adaptación.
- **Mejorar de *sample-efficiency*:**
 - Investigar métodos que permitan aprender modelos precisos con pocos datos.
 - Explorar meta-aprendizaje para que los agentes aprendan a modelar dinámicas más rápido y se adapten mejor a nuevas tareas.
- **Buffer de repetición:**
 - Diseñar estrategias para priorizar o filtrar datos dinámicamente, evitando la interferencia de información obsoleta sin perder cobertura del espacio de estados.

- Desarrollar técnicas para detectar y eliminar datos desactualizados en el buffer.
- Implementar repetición de experiencias priorizada para enfocarse en las transiciones más relevantes.
- **Nuevas arquitecturas:**
 - Diseñar modelos y objetivos de entrenamiento que promuevan mejor generalización y adaptación.
 - Investigar el uso de modelos probabilísticos para manejar la incertidumbre y mejorar la robustez ante cambios en el entorno.
- **Sesgo/Varianza:**
 - Investigar cómo detectar y mitigar los sesgos en sistemas de decisión automática para mejorar su impacto positivo.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*. The MIT Press, second ed., 2018. 3
- [2] T. Wang, X. Bao, I. Clavera, J. Hoang, Y. Wen, E. Langlois, S. Zhang, G. Zhang, P. Abbeel, and J. Ba, “Benchmarking model-based reinforcement learning,” 2019. 3, 4
- [3] Y. Wan, A. Rahimi-Kalahroudi, J. Rajendran, I. Momennejad, S. Chandar, and H. van Seijen, “Towards evaluating adaptivity of model-based reinforcement learning methods,” 2022. 3, 4, 7, 9, 11
- [4] J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, T. Lillicrap, and D. Silver, “Mastering atari, go, chess and shogi by planning with a learned model,” *Nature*, vol. 588, p. 604–609, Dec. 2020. 3
- [5] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “Imagenet: A large-scale hierarchical image database,” in *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 248–255, 2009. 4
- [6] Y. Duan, X. Chen, R. Houthoofd, J. Schulman, and P. Abbeel, “Benchmarking deep reinforcement learning for continuous control,” 2016. 4
- [7] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang, and W. Zaremba, “Openai gym,” 2016. 4
- [8] Y. Tassa, Y. Doron, A. Muldal, T. Erez, Y. Li, D. de Las Casas, D. Budden, A. Abdolmaleki, J. Merel, A. Lefrancq, T. Lillicrap, and M. Riedmiller, “Deepmind control suite,” 2018. 4
- [9] H. van Seijen, H. Nekoei, E. Racah, and S. Chandar, “The loca regret: A consistent metric to evaluate model-based behavior in reinforcement learning,” 2020. 5
- [10] D. Hafner, T. Lillicrap, I. Fischer, R. Villegas, D. Ha, H. Lee, and J. Davidson, “Learning latent dynamics for planning from pixels,” 2019. 7